15. Mini-projekt — Matplotlib
Eksploracyjna analiza cen mieszkań

Teraz połączymy poznane techniki. Wyobraź sobie, że otrzymujesz zbiór danych o nieruchomościach. Chcesz przygotować wstępny raport, zanim rozpoczniesz budowanie modelu przewidującego ceny mieszkań.

Nie będziemy jeszcze tworzyli modelu. Naszym zadaniem będzie **wizualna eksploracja danych**.

Krok 1. Generujemy przykładowy zbiór

Zaimportuj:

```
import numpy as np
import matplotlib.pyplot as plt
```

Wpisz:

```
rng = np.random.default_rng(2026)

area = rng.uniform(30, 180, 250)
distance = rng.uniform(0, 20, 250)

price = (
    125 + 3.2 * area - 2.5 * distance
    + rng.normal(0, 45, 250)
)

price = np.clip(price, 70, None)
```

Zmienna `area` oznacza powierzchnię w metrach kwadratowych, `distance` — odległość od centrum w kilometrach, a `price` — cenę w tysiącach złotych.

Krok 2. Przygotowujemy cztery wykresy

Na jednym rysunku utworzymy:

1. Histogram cen mieszkań.
2. Zależność ceny od powierzchni.
3. Zależność ceny od odległości od centrum.
4. Wykres pudełkowy cen w trzech grupach powierzchni.

```
fig, axes = plt.subplots(2, 2, figsize=(11, 7))

# Histogram
axes[0, 0].hist(
    price, bins=25,
    color="steelblue",
    edgecolor="white"
)
```

```
axes[0, 0].set_title("Rozkład cen mieszkań")

# Cena a powierzchnia
axes[0, 1].scatter(
    area, price,
    alpha=0.5, color="teal"
)
axes[0, 1].set_title("Cena a powierzchnia")

# Cena a odległość
axes[1, 0].scatter(
    distance, price,
    alpha=0.5, color="darkorange"
)
axes[1, 0].set_title("Cena a odległość od centrum")

# Podział mieszkań według powierzchni
small = price[area < 70]
medium = price[(area >= 70) & (area < 120)]
large = price[area >= 120]

axes[1, 1].boxplot(
    [small, medium, large],
    tick_labels=["Małe", "Średnie", "Duże"]
)
axes[1, 1].set_title("Cena według wielkości mieszkania")

for ax in axes.flat:
    ax.grid(alpha=0.2)
    ax.set_axisbelow(True)

fig.suptitle("Eksploracyjna analiza cen mieszkań")
fig.tight_layout()

plt.show()
```

Krok 3. Interpretacja wyników

Odpowiedz na pytania:

1. Czy ceny mieszkań mają rozkład symetryczny?
2. Czy większa powierzchnia wiąże się zwykle z wyższą ceną?
3. Czy odległość od centrum ma widoczny związek z ceną?
4. W której kategorii mieszkań występuje największy rozrzut cen?
5. Czy na wykresach widoczne są wartości odstające?
6. Czy na podstawie tych wizualizacji można już jednoznacznie określić przyczyny różnic cen?

Krok 4. Rozbudowa mini-projektu

Samodzielnie:

- Dodaj opisy i jednostki do osi wszystkich wykresów.
- Zaznacz na histogramie średnią i medianę.
- Zmień przezroczystość punktów na wykresach punktowych.
- Oblicz i wyświetl korelację ceny z powierzchnią.
- Zapisz raport jako grafikę PNG.

Wyzwanie dodatkowe

Spróbuj zmienić syntetyczny model generowania cen tak, aby odległość od centrum miała większy wpływ na cenę mieszkania.

Zmień współczynnik:

```
-2.5 * distance
```

na:

```
-8 * distance
```

Następnie wygeneruj wykresy ponownie.

Pytanie: Które wizualizacje najlepiej pokazały zmienioną zależność?

16. Jak dobrać rodzaj wykresu?

Przed utworzeniem wizualizacji warto zadać sobie pytanie:

Jaką informację chcę przekazać odbiorcy?

Pytanie analityczne	Najlepszy punkt wyjścia
Jak wartość zmienia się w czasie?	Wykres liniowy
Czy dwie zmienne są ze sobą powiązane?	Wykres punktowy
Jak wygląda rozkład zmiennej?	Histogram
Czy w danych występują wartości odstające?	Boxplot
Która kategoria ma najwięcej obserwacji?	Wykres słupkowy
Jak silnie powiązane są liczne cechy?	Heatmapa korelacji
Gdzie model klasyfikacyjny się myli?	Macierz pomyłek
Czy model regresyjny ma błąd systematyczny?	Wykres reszt
Jak zmienia się jakość modelu podczas treningu?	Krzywe uczenia
Jak porównać kilka aspektów zbioru?	Subplots

Zasady dobrego wykresu

Dobry wykres powinien być nie tylko estetyczny, ale również uczciwy informacyjnie.

Pamiętaj o kilku zasadach:

1. **Opisuj osie i jednostki.** Odbiorca musi wiedzieć, co oznaczają wartości.
2. **Stosuj odpowiedni typ wykresu.** Nie każde dane należy przedstawiać linią lub słupkami.
3. **Uważaj na skalę osi.** Nieodpowiednie zakresy mogą wyolbrzymiać lub ukrywać różnice.
4. **Nie używaj nadmiaru kolorów.** Kolor powinien pomagać w odczytywaniu informacji.
5. **Pokazuj rozkład danych.** Sama średnia może ukrywać wartości odstające i asymetrię.
6. **Unikaj nadmiernej liczby elementów.** Siatka, legenda i adnotacje powinny zwiększać czytelność.
7. **Nie wyciągaj wniosków przyczynowych wyłącznie z korelacji.**
8. **Pamiętaj o pochodzeniu danych.** Dane syntetyczne pomagają w nauce, ale nie zastępują analizy rzeczywistych zbiorów.

Podsumowanie laboratorium

Po ukończeniu ćwiczeń powinnaś/powinieneś potrafić:

- importować Matplotlib i używać `pyplot`,
- rozróżniać obiekty `Figure` i `Axes`,
- tworzyć wykresy liniowe, punktowe i słupkowe,
- analizować rozkłady za pomocą histogramów i boxplotów,
- używać przezroczystości, kolorów i rozmiarów znaczników,
- dodawać tytuły, etykiety, legendy i siatki pomocnicze,
- porównywać pomiary wraz z miarą zmienności,
- tworzyć mapy cieplne macierzy danych,
- wizualizować błędy modeli uczenia maszynowego,
- przygotowywać wykresy składowe za pomocą `subplots()`,
- zapisywać wykresy do plików PNG, SVG i PDF,
- dobierać rodzaj wykresu do pytania analitycznego.

Najważniejsza idea

W NumPy i Pandas nauczyliśmy się przechowywać i przetwarzać dane.

Matplotlib pozwala nam przejść od samych wartości liczbowych do **wizualnego rozumienia danych**.

W Data Science wykres nie jest jedynie ozdobą raportu. Jest narzędziem badawczym, które pomaga formułować hipotezy, znajdować błędy, odkrywać zależności i oceniać modele.

Literatura

1. Wes McKinney, *Python w analizie danych*, rozdział 9: „Wykresy i wizualizacja danych” — w szczególności podrozdział 9.1 „Podstawy obsługi interfejsu pakietu matplotlib”.
2. Aurelien Geron, *Nasz pierwszy projekt uczenia maszynowego*, rozdział 2 — w szczególności zagadnienia odkrywania i wizualizacji danych, histogramów, wykresów punktowych, analizowania zależności i korelacji.

Przykłady laboratoryjne zostały opracowane na potrzeby zajęć Data Science. Wykorzystują mechanizmy omawiane w rozdziałach oraz dodatkowe, powszechnie stosowane techniki wizualizacji modeli i danych.